Dossier de conception

Groupe 5

Membre de l'équipe: Chenxin FENG, Jiayu WANG

‘

12/02/2026

Table des matières

1 Contexte

2 Source de données

3 Architecture

4 ETL

4.1 Extrait

4.1.1 Description de l'API et structure des données

4.1.2 EventBridge

4.1.3 Lambda1Extract

4.2 Transformation et Loading - Lambda2Clean

5 Requête SQL - Athena

5.1 Validation du chargement des données

5.2 Cas d'analyse des données

6 Visualisation

7 Conclusion

1 Contexte

Ce projet s'inscrit dans une démarche de data engineering visant à concevoir une architecture AWS permettant l'extraction, la transformation et le stockage automatisé de données ouvertes publiées par Toulouse Métropole.

L'objectif principal est de normaliser ces données afin de les rendre exploitables via des requêtes SQL, dans une perspective d'analyse statistique et décisionnelle.
L'ensemble du projet a été réalisé dans l'environnement AWS Sandbox fourni par Amazon Academy, garantissant un cadre pédagogique sécurisé et isolé

2 Source de données

2.1 Description de données

Le jeu de données sélectionné provient de la plateforme open data de Toulouse Métropole, plus précisément du dataset « Station météo Toulouse Basso Cambo ».
Il couvre la période allant du 20 juin 2019 à 01:00 (heure de Paris) jusqu'à aujourd'hui et contient des mesures météorologiques mises à jour théoriquement toutes les quinze minutes (*xx:00, xx:15, xx:30, xx:45*).

Cependant, une analyse exploratoire des données révèle que la fréquence de mise à jour n'est pas systématiquement respectée. Notamment pour l'année 2026, la majorité des observations disponibles correspondent uniquement à l'enregistrement de 00:15 (heure de Paris), ce qui soulève une problématique de complétude temporelle des données.

2.2 Source de données

Lien de la source de données : https://data.toulouse-metropole.fr/explore/dataset/08-station-meteo-toulouse-basso-cambo/table/?sort=-type_de_station&refine.pluie=0.0

Tableau 1 Dictionnaire des attributs

Nom	Définition	Foramt source
heure_utc	heure UTC	2021-12-23T11:30:00+00:00
heure_de_paris	heure sur le fuseau horaire de Paris	2021-12-23T11:30:00+00:00
temperature_en_degre_c	température moyenne des 15 dernières minutes	9 °C
humidite	Valeur d'humidité en pourcentage	91 %
pression	valeur de pression. La valeur contenues dans ce champ doivent être additionnées à 900	100 400 Pa
pluie	quantité de précipitation en mm	0 mm
pluie_intensite_max	Intensité maximale de pluie sur une minute	0 mm
force_moyenne_du_vecteur_vent	force du vecteur de vent (norme). En km/h	0 km/h
direction_du_vecteur_vent_moyen	Angle entre la direction de laquelle vient vent par rapport à une référence cardinale qui est ici le nord	0 km/h

direction_du_vecteur_de_vent_max	Cette valeur représente la direction de la rafale maximum sur les 15 minutes précédentes. Allant de 0 à 15, donne une indication sur l'angle en degré par rapport au nord(sens horaire).	0 - 0° … 15 - 337.5°
direction_du_vecteur_de_vent_max_en_degres	Angle entre la direction de laquelle vient vent par rapport à une référence cardinale qui est ici le nord	337,5 °
force_rafale_max	Vitesse maximale du vent dans les 15 dernières minutes	2 km/h
data	message brut en provenance de la station météo	1057558e468800000b1e0800
id	Identifiant de la station la station n°1 est celle de la météopole	8
type_de_station	Il existe deux types de station : Integrated Sensor Suite(ISS) regroupant uncapteur de :Température, Humidité, Anémomètre, Pluviomètre, Capteur de Pression	ISS

3 Architecture

3.1 L'architecture fonctionnelle

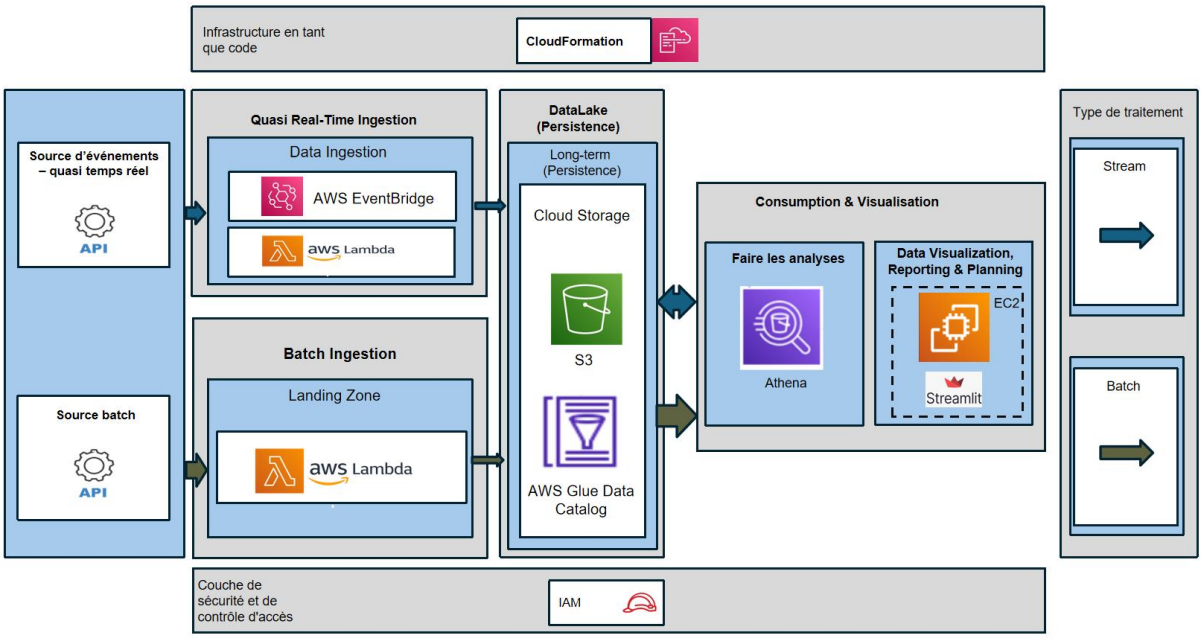

figure 1 L'architecture fonctionnelle

La figure 1 présente une architecture en couches déployée sur AWS. Elle distingue clairement les différentes étapes du traitement des données : ingestion, stockage, analyse et visualisation.

L'infrastructure est provisionnée à l'aide d'AWS CloudFormation, garantissant un déploiement automatisé et reproductible des ressources.、

Les données météorologiques sont collectées via une API publique. L'ingestion est assurée par AWS Lambda, déclenchée périodiquement par Amazon EventBridge dans un mode quasi temps réel (toutes les quinze minutes), ainsi que par un mode batch pour le chargement initial ou historique.

Les données sont stockées dans Amazon S3, constituant le data lake du projet. AWS Glue Data Catalog gère les métadonnées et permet leur exploitation par Amazon Athena.

L'analyse des données est réalisée à l'aide d'Athena via des requêtes SQL. Les résultats sont ensuite exploités dans une application Streamlit déployée sur une instance EC2, permettant la visualisation interactive des données.

La sécurité et le contrôle d'accès sont assurés par AWS IAM, qui définit les rôles et permissions associés aux différents services.

3.2 L'architecture technique

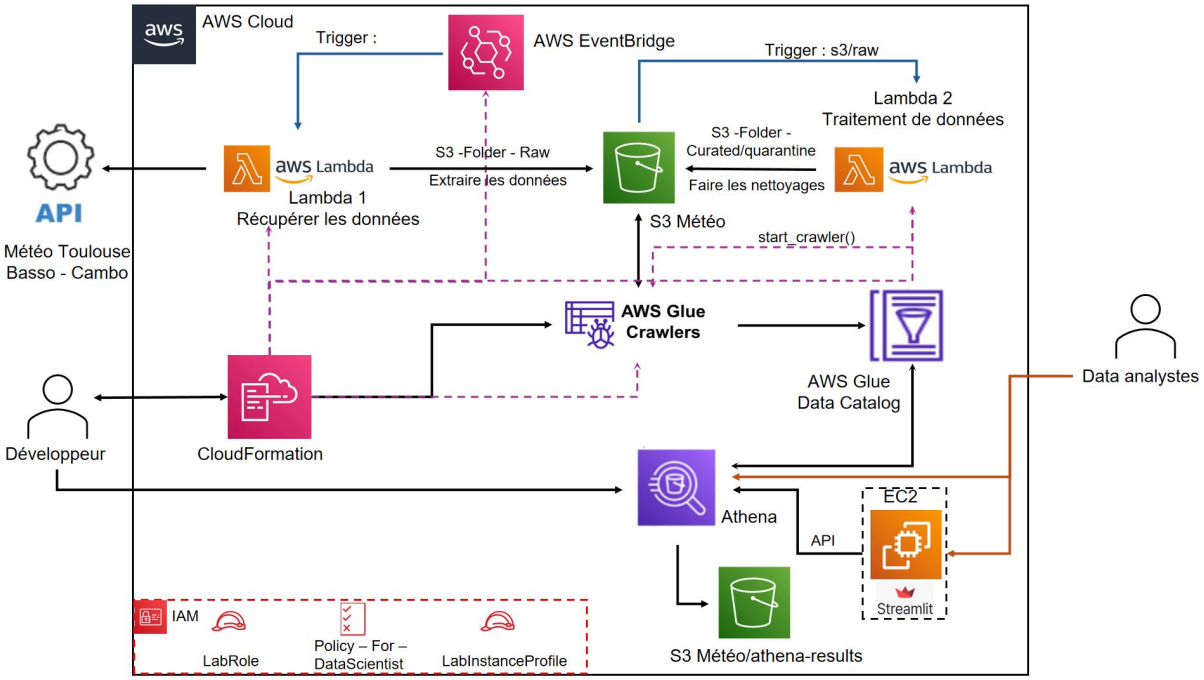

figure 2 L'architecture technique

La figure 2 affiche l'implémentation technique détaillée du pipeline de traitement des données.

L'extraction des données météorologiques est assurée par une fonction AWS Lambda (Lambda 1), déclenchée périodiquement par Amazon EventBridge. Cette fonction interroge l'API publique et enregistre les données brutes dans un dossier raw au sein du bucket Amazon S3.

Le dépôt de nouveaux fichiers dans le dossier raw déclenche automatiquement une seconde fonction Lambda (Lambda 2), chargée du traitement et de la validation des données. Cette étape applique les règles de contrôle définies précédemment et répartit les enregistrements dans deux espaces distincts :

- curated pour les données valides,

- quarantine pour les données présentant des anomalies.

Une fois les données validées, AWS Glue Crawler est lancé afin de mettre à jour le AWS Glue Data Catalog. Celui-ci enregistre les métadonnées (schéma, partitions) nécessaires à l'interrogation des données.
Amazon Athena permet ensuite d'exécuter des requêtes SQL directement sur les données stockées dans S3, en s'appuyant sur le Glue Data Catalog. Les résultats des requêtes sont stockés dans un bucket S3 dédié.
Enfin, une application Streamlit déployée sur une instance EC2 interagit avec Athena via son API afin de récupérer les résultats et de les présenter aux analystes sous forme de visualisations interactives.

L'ensemble des ressources (Lambda, S3, EventBridge, Glue, IAM, Athena) est déployé et configuré à l'aide d'AWS CloudFormation. La gestion des accès est assurée par AWS IAM à travers des rôles et des politiques associés aux différents services.

4 ETL

Cette section décrit le pipeline ETL mis en place pour automatiser le traitement des données météorologiques.

L'architecture repose sur une approche serverless combinant Amazon EventBridge, AWS Lambda et Amazon S3 afin d'assurer l'ingestion, la transformation et le stockage structuré des données.
Les données sont organisées dans le data lake selon trois niveaux : raw, curated et quarantine, permettant de garantir la traçabilité et la qualité des informations.

Les sous-sections suivantes détaillent successivement les différentes étapes du processus.

4.1 Extrait

L'analyse du dataset indique que les données météorologiques sont accessibles via une API publique et font l'objet de mises à jour régulières. Afin de mettre en place un processus d'ingestion automatisé et scalable, une architecture serverless basée sur les services managés d'AWS a été déployée.

Le déclenchement de l'extraction repose sur Amazon EventBridge, configuré avec une règle(*cron(5/15 * * * ? *)*) planifiée permettant d'exécuter périodiquement une fonction AWS Lambda. Cette approche orientée événements assure l'automatisation du flux de données sans dépendance à une infrastructure serveur dédiée.

La fonction Lambda agit comme composant d'ingestion. Elle interroge l'API externe, récupère les nouvelles observations disponibles et les prépare pour leur stockage. Les autorisations nécessaires sont gérées via un rôle IAM (LabRole), garantissant un contrôle d'accès conforme au principe du moindre privilège (principle of least privilege).

Les données brutes sont ensuite déposées dans un bucket Amazon S3, au sein du répertoire raw/. Ce stockage constitue la couche d'ingestion (*data lake – raw layer*) et permet d'assurer la traçabilité, la durabilité et la séparation des responsabilités dans le pipeline de données.

Cette architecture orientée services managés présente plusieurs avantages : scalabilité automatique, haute disponibilité, réduction des coûts d'infrastructure et simplification des opérations.

4.1.1 Description de l'API et structure des données

Le jeu de données est accessible via l'API REST officielle fournie par la plateforme open data de Toulouse Métropole.

L'Endpoint utilisé pour l'extraction est le suivant :

/api/explore/v2.1/catalog/datasets/08-station-meteo-toulouse-basso-cambo/records?limit=20&refine=pluie%3A%220.0%22

Cette API permet de récupérer les enregistrements au format JSON et supporte différents paramètres de requête, notamment :

- limit : nombre maximal d'enregistrements retournés
- refine : filtre appliqué sur un attribut spécifique

- pagination pour l'extraction en volume

La réponse renvoyée par l'API est structurée sous forme de document JSON contenant deux éléments principaux :

- total_count : nombre total d'enregistrements disponibles
- results : liste des observations météorologiques

Chaque observation comprend les attributs météorologiques suivants :

- humidité (*humidite*)
- température (*temperature_en_degre_c*)
- pression atmosphérique (*pression*)
- précipitations (*pluie, pluie_intensite_max*)
- vent (*force moyenne, rafale maximale, direction codée et direction en degrés*)
- horodatage (*heure_de_paris*, *heure_utc*)
- type de station (*type_de_station*)

Un exemple simplifié de structure retournée est présenté ci-dessous :


```
{
"total_count":146174,
"results":[
{
"data":"119725ef4ab00000cc8c6000",
"id":8,
"humidite":86,
"direction_du_vecteur_de_vent_max":6,
"pluie_intensite_max":0,
"pression":100000,
"direction_du_vecteur_vent_moyen":0,
"type_de_station":"ISS",
"pluie":0,
"direction_du_vecteur_de_vent_max_en_degres":135,
"force_moyenne_du_vecteur_vent":6,
"force_rafale_max":24,
"temperature_en_degre_c":11.2,
"heure_de_paris":"2021-12-23T11:30:00+00:00",
"heure_utc":"2021-12-23T11:30:00+00:00"
},
...}
```

4.1.2 EventBridge

Selon la documentation officielle, le dataset est mis à jour toutes les quinze minutes. L'observation empirique des données confirme que les enregistrements apparaissent généralement aux horaires suivants : xx:00, xx:15, xx:30 et xx:45.

Afin d'optimiser la fiabilité de l'ingestion et d'éviter tout risque lié à un léger retard de publication des données, le déclenchement de l'extraction a été volontairement configuré cinq minutes après ces créneaux théoriques, soit aux horaires xx:05, xx:20, xx:35 et xx:50.
Cette stratégie permet de garantir que les nouvelles données sont effectivement disponibles au moment de l'appel API, améliorant ainsi la cohérence temporelle du pipeline. En conséquence, le bucket S3 reflète également une fréquence d'actualisation toutes les quinze minutes.

Amazon EventBridge a été utilisé comme mécanisme de planification (*scheduled rule - cron(5/15 * * * ? *)*) afin de déclencher automatiquement la fonction Lambda1. Cette approche s'inscrit dans une architecture orientée événements (*event-driven architecture*), permettant l'exécution périodique du code d'extraction sans infrastructure serveur dédiée.

La fonction Lambda1, contenant la logique d'interrogation de l'API et de stockage des données, est ainsi invoquée automatiquement selon la règle définie dans EventBridge. Cette configuration assure :

- l'automatisation complète du processus d'ingestion,
- la scalabilité native du système,
- et la réduction des coûts liés à l'infrastructure.

L'utilisation combinée d'EventBridge et de Lambda permet donc de mettre en œuvre un pipeline serverless fiable, découplé et hautement disponible.

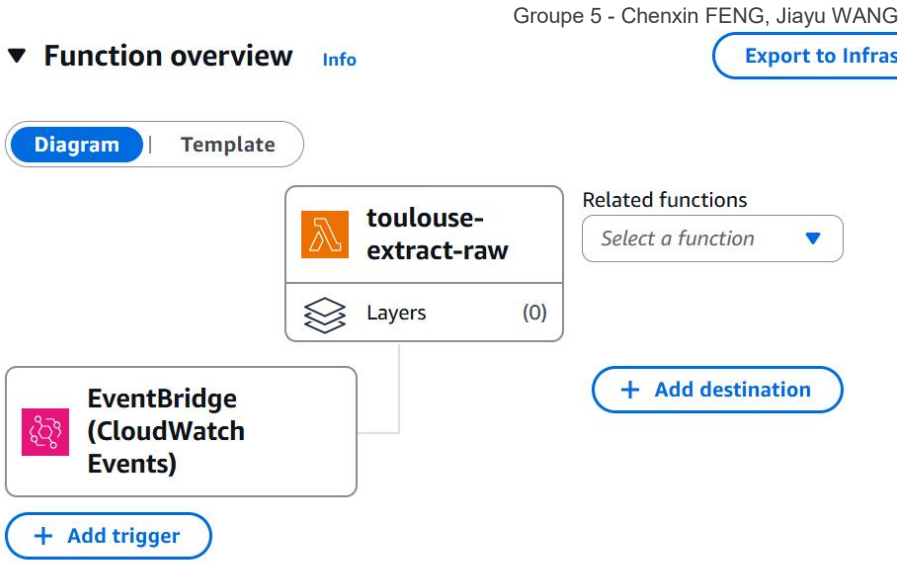

figure 3 Les services d'extrait

4.1.3 Lambda1Extract

La fonction Lambda1Extract constitue le composant d'ingestion du pipeline. Elle est déclenchée périodiquement par une règle planifiée EventBridge et interroge l'API Open Data de Toulouse Métropole afin de récupérer les nouveaux enregistrements disponibles.

1) Logique d'extraction (incremental / bootstrap)

Deux modes d'exécution sont prévus :

- bootstrap : initialisation (chargement historique) à partir d'une date de départ fixe (*ex. 2019-01-01*) ;
- incremental : ingestion continue des nouvelles données, utilisée en production.

Dans les deux cas, la fonction s'appuie sur un mécanisme de checkpoint stocké dans S3 (fichier texte dans metadata/…) afin de conserver un "watermark" temporel correspondant au dernier timestamp extrait. Ce watermark permet d'éviter les doublons et d'assurer une extraction strictement incrémentale via une condition de type :

- heure_de_paris > last_watermark

Pour le mode incrémental, une stratégie de backfill (ex. 7 jours) est appliquée lors d'une première exécution en l'absence de checkpoint, afin de limiter le risque de perte de données en cas de retard de publication ou d'indisponibilité temporaire.

2) Appel API, pagination et contrôle d'exécution

Lambda1 interroge l'endpoint /records en spécifiant :

- un tri temporel (order_by = heure_de_paris) ;
- un filtre where basé sur le watermark ;
- un limit afin de contrôler le volume par appel.

La fonction surveille également son temps d'exécution et interrompt la boucle d'extraction si le temps restant devient insuffisant, afin de respecter les contraintes du runtime Lambda.

3) Stockage S3 : couche raw et partitionnement

Les données extraites sont stockées au format JSON dans Amazon S3, au sein de la couche raw/, sans transformation sur les champs métiers. Chaque lot est enregistré sous forme d'un fichier horodaté et organisé selon une structure de partitionnement, par exemple :

- raw/mode=<mode>/year=YYYY/month=MM/day=DD/batch_<timestamp>.json

Cette organisation facilite :

- la traçabilité (lots horodatés),
- l'exploitation ultérieure par Glue/Athena (partitionnement),
- et la séparation claire entre ingestion brute et données normalisées.

Chaque enregistrement est enrichi d'un champ technique ingestion_ts correspondant au moment de collecte, permettant d'auditer le pipeline et de distinguer l'horodatage métier (mesure) de l'horodatage d'ingestion.

4) Sécurité et permissions

La fonction Lambda est associée au rôle IAM LabRole, qui fournit les permissions nécessaires (accès en écriture au bucket S3 et lecture des métadonnées). Cette gestion centralisée des accès garantit une exécution sécurisée du composant d'ingestion dans un contexte serverless.

5) Initialisation du chargement historique

Lors du déploiement initial de la fonction, une première exécution en mode bootstrap doit être effectuée en fournissant l'événement suivant :

```
{"mode": "bootstrap"}
```

Ce mode permet de déclencher le chargement historique complet du dataset à partir de la date de départ définie.
En raison des limitations de durée d'exécution d'AWS Lambda, le chargement complet peut nécessiter plusieurs exécutions successives du mode bootstrap. Le mécanisme de checkpoint (watermark stocké dans S3) garantit cependant la reprise automatique à partir du dernier horodatage traité, évitant ainsi toute duplication de données.
Une fois l'initialisation terminée, le pipeline bascule en mode incremental, déclenché automatiquement par EventBridge.

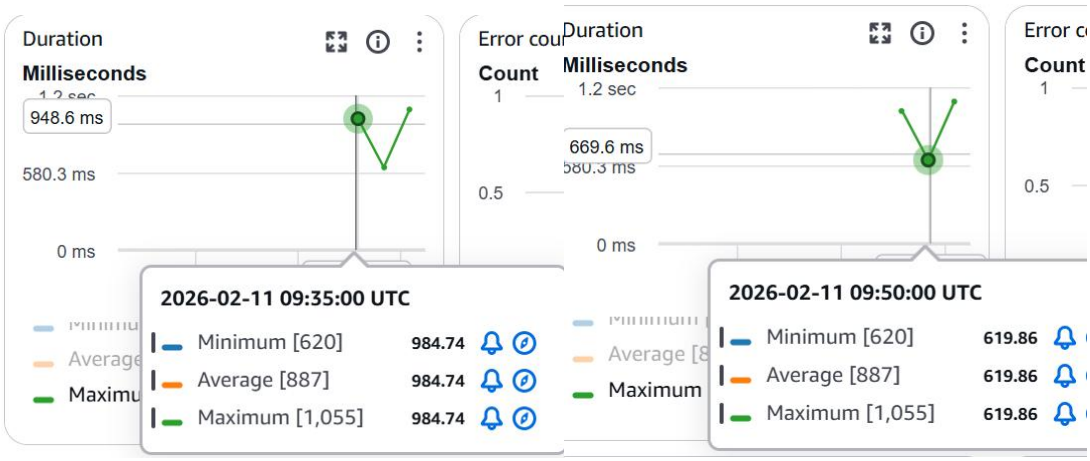

figure 4 Exemple d'exécution de lambda1 lors du test initial

4.2 Transformation et Loading - Lambda2Clean

La fonction Lambda2Clean constitue la couche de transformation du pipeline ETL. Elle est automatiquement déclenchée par un événement S3 à chaque ajout d'un nouveau fichier dans le répertoire raw/.

Ce mécanisme permet d'assurer un traitement asynchrone et entièrement automatisé des données fraîchement ingérées, conformément à une architecture orientée événements.

L'analyse des données sources a révélé la présence de valeurs aberrantes, telles que des températures extrêmement basses (*-50°C*), justifiant la mise en place de règles de validation et de contrôle qualité.

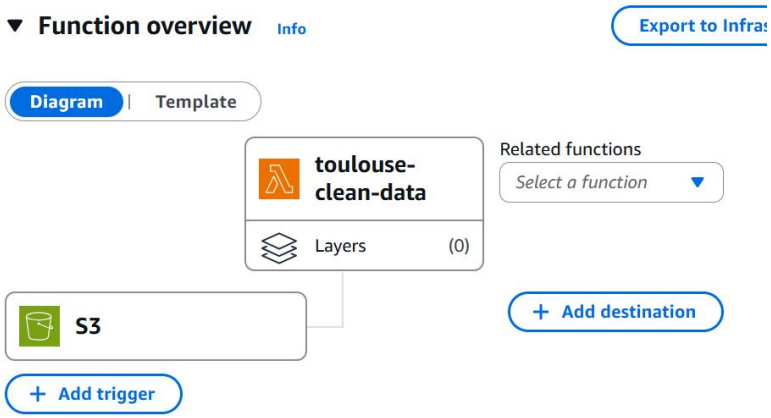

figure 5 Les services de transformation

1) Déclenchement automatique

Lorsqu'un fichier JSON est déposé dans S3/raw/, un événement ObjectCreated active Lambda2. La fonction :

a. Lit le contenu brut du fichier.
b. Extrait la liste des enregistrements météorologiques.
c. Applique les règles de validation définies dans le dictionnaire des contraintes (*Tableau 2*).

Ainsi, chaque lot de données est traité immédiatement après son ingestion, garantissant la cohérence du pipeline.

2) Normalisation et validation

Avant validation, les valeurs sont normalisées afin de garantir un typage cohérent :

- Conversion des chaînes contenant des unités ("9 °C", "100 400 Pa", "337,5") en valeurs numériques.

- Standardisation des séparateurs décimaux.
- Gestion des valeurs nulles ou non interprétables.

Les données sont ensuite contrôlées selon des contraintes métier :

- bornes numériques (température, pression, humidité, vent, pluie),
- validation des angles (0–360 degrés),
- validation des codes directionnels (0–15),
- contrôle des types et des valeurs manquantes.

Tableau 2 Dictionnaire des contraintes de validation

Nom	Foramt source	Validation rule
heure_utc	2021-12-23T11:30:00+00:00	ISO 8601 datetime format (UTC), must be parseable timestamp
heure_de_paris	2021-12-23T11:30:00+00:00	ISO 8601 datetime format, converted to Europe/Paris timezone
temperature_en_degre_c	9 °C	Numeric, range −20 to 50 °C
humidite	91 %	Numeric, range 0–100 %
pression	100 400 Pa	Numeric (unit removed), range 90 000–110 000 Pa
pluie	0 mm	Numeric, ≥ 0 and ≤ 500 mm

pluie_intensite_max	0 mm	Numeric, ≥ 0 and ≤ 200 mm/min
force_moyenne_du_vecteur_vent	0 km/h	Numeric, ≥ 0 and ≤ 250 km/h
direction_du_vecteur_vent_moyen	0 km/h	Angle, numeric, 0–360 degrees
direction_du_vecteur_de_vent_max	0 - 0° … 15 - 337.5°	Encoded integer category, range 0–15
direction_du_vecteur_de_vent_max_en_degres	337,5 °	Numeric angle, 0–360 degrees
force_rafale_max	2 km/h	Numeric, ≥ 0 and ≤ 250 km/h

3) Séparation des flux : curated vs quarantine

À l'issue de la validation, chaque enregistrement est orienté vers l'un des deux flux suivants :

- curated/ : contient les données conformes aux règles définies ;
- quarantine/ : contient les enregistrements présentant au moins une anomalie, accompagnés d'un champ anomaly_reasons décrivant la nature du problème détecté.

Cette séparation permet :

- d'éviter la contamination du dataset analytique,
- de conserver une traçabilité complète des anomalies,
- et de faciliter l'audit et l'amélioration continue des règles de validation.

Les fichiers produits sont organisés selon un partitionnement temporel (year/month/day), garantissant une compatibilité optimale avec AWS Glue et Amazon Athena.

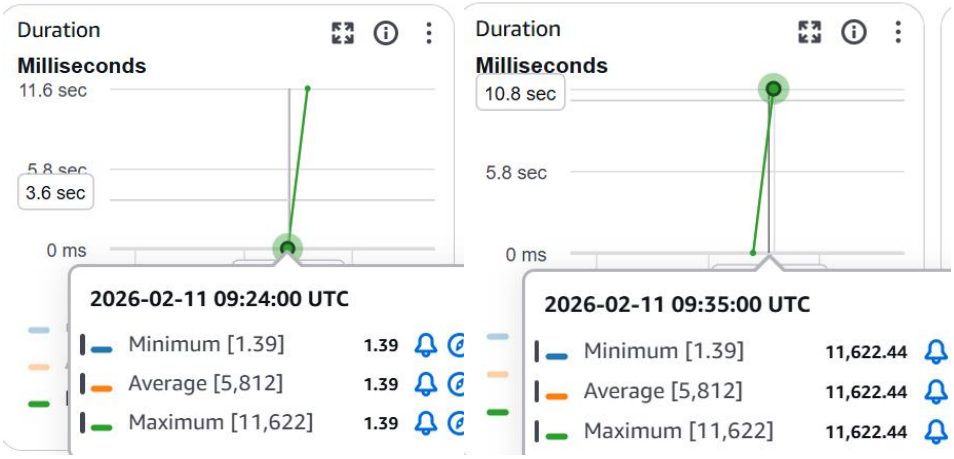

figure 6 Exemple d'exécution de Lambda2 lors du test initial

4) Intégration avec Glue et couche analytique

Lorsque des données valides sont écrites dans le dossier curated/, la fonction déclenche automatiquement un AWS Glue Crawler. Celui-ci met à jour le catalogue de données (Data Catalog), permettant aux tables Athena de refléter les nouvelles partitions disponibles.

Ce mécanisme assure une mise à jour continue de la couche analytique sans intervention manuelle.

5) Rôle architectural

Lambda2 assure ainsi :

- la qualité des données (data quality enforcement),
- la gouvernance du data lake (séparation raw / curated / quarantine),
- et la préparation des données pour l'analyse SQL.

Combinée à Lambda1 et EventBridge, elle complète un pipeline ETL serverless, scalable et entièrement automatisé.

5 Requête SQL - Athena

Une fois les données chargées en mode bootstrap (chargement complet), puis en mode incrémental, et après le scan automatique de la structure réalisé par AWS Glue Crawler, une base de données nommée toulouse_weather_db est créée dans AWS Glue. Cette base contient une table associée au répertoire curated/ ce qui permet d'interroger exclusivement les données validées et nettoyées. Afin de s'assurer que le chargement complet ou incrémental s'est déroulé correctement, des requêtes statistiques peuvent être exécutées via Amazon Athena. De plus, pour approfondir l'analyse des données et préparer leur exploitation dans une phase ultérieure de visualisation, des requêtes SQL peuvent également être lancées dans Amazon Athena afin de réaliser des analyses exploratoires et des contrôles complémentaires.

5.1 Validation du chargement des données

Etant donné que le volume des données brutes est relativement important, il est nécessaire, avant d'effectuer des analyses plus approfondies, de vérifier que Lambda1 a bien réalisé l'extraction complète des données et que Lambda2 a correctement exécuté le processus de nettoyage.Une fois que le statut d'exécution du AWS Glue Crawler est affiché comme 'Ready', utilise des requêtes SQL suivant peuvent être exécutées dans Amazon Athena afin de vérifier, en coordination avec le mécanisme d'ingestion de Lambda1, que le chargement a bien été effectué :

```
SELECT substr(heure_de_paris, 1, 4) as extracted_year, COUNT(*) as
record_count, MIN(heure_de_paris) as earliest_record,
MAX(heure_de_paris) as latest_record

FROM "toulouse_weather_db"."curated"

GROUP BY substr(heure_de_paris, 1, 4)

ORDER BY extracted_year ASC;
```

Cliquer sur 'Run', la requête SQL mentionnée ci-dessus a été exécutée et les données ont été agrégées selon la date de capture. Les résultats permettent de calculer chaque année entre 2019 et 2026, le nombre total d'enregistrements ainsi que la date de collecte la plus ancienne et la plus récente. En comparant ces résultats avec le volume des données sources, il est possible de constater que la

fonction Lambda a correctement collecté les données pour chaque année. La distribution observée est cohérente avec les métadonnées initiales, ce qui confirme que la fonction Lambda a bien assuré l'ingestion complète ainsi que le nettoyage des données (figure 7) :

Completed | Time in queue: 103 ms | Run time: 1.6 sec | Data scanned: 48.04 MB

Results (8) | Copy | Download results CSV

Search rows

#	extracted_year	record_count	earliest_record	latest_record
1	2019	12100	2019-06-19T02:00:00+02:00	2019-12-31T17:00:00+01:00
2	2020	23000	2020-01-01T16:15:00+01:00	2020-12-31T16:30:00+01:00
3	2021	17600	2021-01-01T15:45:00+01:00	2021-12-31T22:45:00+01:00
4	2022	22878	2022-01-01T22:00:00+01:00	2022-12-31T23:45:00+01:00
5	2023	15022	2023-01-01T00:00:00+01:00	2023-12-29T03:45:00+01:00
6	2024	5141	2024-01-01T03:00:00+01:00	2024-12-31T00:15:00+01:00
7	2025	172	2025-01-01T00:15:00+01:00	2025-12-31T00:15:00+01:00
8	2026	50	2026-01-01T00:15:00+01:00	2026-02-10T00:15:00+01:00

figure 7 Exemple de surveillant de la chargement de données

5.2 Cas d'analyse des données

Pour analyser plus largement les données collectées au cours des six dernières années par la station de Toulouse Basso Cambo, à cette étape, l'analyse a été structurée selon différents niveaux de granularité. Des exemples d'analyses ont ainsi été proposés successivement selon cinq axes :

1) Analyse descriptive macro

Afin d'identifier de manière préliminaire les variations saisonnières du climat, d'observer les différences globales entre les années et d'établir une base temporelle de référence, une agrégation mensuelle des données collectées a été réalisée à un niveau macro, avec calcul des valeurs moyennes .Les résultats obtenus via les requêtes SQL permettent d'observer une élévation significative des températures en été et une baisse marquée en hiver. Par ailleurs, l'humidité apparaît relativement plus élevée durant les périodes de basse température et plus faible pendant les périodes chaudes, ce qui reflète une structure climatique régionale typique. Enfin, la vitesse du vent présente des fluctuations relativement stables, sans anomalies significatives observées.

Query results | Query stats

Completed — Time in queue: 98 ms — Run time: 1.201 sec — Data scanned: 95.18 MB

Results (71) — Copy — Download results CSV

Search rows — 1

#	annee	mois	temperature_moyenne	humidite_moyenne	vent_moyen
1	2019	6	24.99	62.25	6.48
2	2019	7	25.16	61.14	4.86
3	2019	8	23.91	66.22	2.6
4	2019	9	20.33	64.53	3.93
5	2019	10	15.91	80.83	3.76
6	2019	11	9.27	86.61	3.93
7	2019	12	9.59	87.21	5.78
8	2020	1	7.69	84.72	2.91
9	2020	2	10.42	79.57	4.25
10	2020	3	10.34	74.77	7.26

figure 8 Informations mensuelles par année

2) Analyse temporelle

Dans les analyses de l'évolution climatique en 2025, les données ont été agrégées au niveau journalier afin de calculer les moyennes quotidiennes de la température, de l'humidité et de la vitesse moyenne du vent à partir des données validées de la table *curated*. Les résultats montrent une évolution progressive de la température, un taux d'humidité globalement élevé et stable en début d'année, tandis que la vitesse moyenne du vent apparaît constante sur la période observée. Cette approche permet d'observer les dynamiques intra-annuelles et constitue une base pour des comparaisons futures.

Completed — Time in queue: 182 ms — Run time: 2.283 sec — Data scanned: 95.18 MB

Results (268) — Copy — Download results CSV

Search rows — 1 ...

#	jour	temperature_moyenne	humidite_moyenne	vent_moyen
1	2025-01-01	4.7	92.0	0.0
2	2025-01-02	10.2	79.0	0.0
3	2025-01-03	7.8	95.0	0.0
4	2025-01-04	8.5	94.0	0.0
5	2025-01-05	11.5	86.0	0.0
6	2025-01-06	6.4	88.0	0.0
7	2025-01-07	9.6	82.0	0.0
8	2025-01-08	8.4	91.0	0.0
9	2025-01-09	9.7	89.0	0.0
10	2025-01-10	12.6	93.0	0.0

figure 9 Résultats des moyennes journalières (température, humidité et vent)

3) Analyse de la structure de distribution

Pour dépasser les limites d'une simple analyse fondée sur les moyennes annuelles, les températures moyennes journalières ont été classifiées en trois catégories selon des seuils prédéfinis : basse (<15°C), modérée (15–25°C) et élevée (≥25°C). Le nombre de jours correspondant à chaque catégorie a ensuite été comptabilisé par année, afin d'observer l'évolution des journées chaudes et d'identifier d'éventuelles transformations de la structure climatique.

Dans la majorité des années, les journées à température basse et modérée représentent la part principale, ce qui indique que la région de la station d'observation conserve globalement un climat tempéré. Le nombre de journées chaudes demeure relativement limité dans la plupart des années, oscillant généralement entre 10 et 30 jours.

Par ailleurs, des variations interannuelles marquées sont observées. Par exemple, en 2022, le nombre de journées chaudes atteint 42, soit une augmentation notable par rapport à 2021 et 2023, traduisant une élévation ponctuelle. Toutefois, cette hausse ne se prolonge pas dans les années suivantes, ce qui suggère que les données reflètent davantage une variabilité interannuelle qu'une tendance stable et continue à l'augmentation.

Query results | Query stats

Completed — Time in queue: 179 ms — Run time: 1.848 sec — Data scanned: 95.18 MB

Results (22) — Copy — Download results CSV

Search rows — 1

#	annee	categorie_temperature	nb_jours
1	2019	Moderate	81
2	2019	High	29
3	2019	Low	62
4	2020	Low	177
5	2020	High	28
6	2020	Moderate	121
7	2021	Moderate	128
8	2021	High	12
9	2021	Low	133
10	2022	High	42

figure 10 Répartition annuelle des catégories de température

4) Analyse des relations entre variables

Dans le but d'analyser l'influence de la pression atmosphérique sur la température, une corrélation annuelle a été calculée à partir des moyennes journalières. Les

résultats montrent une corrélation globalement négative sur la majorité des années observées, indiquant qu'une hausse de la pression est généralement associée à une légère baisse de la température. L'intensité de cette relation varie selon les années, certaines présentant une corrélation plus marquée. Cette analyse permet de mieux comprendre la dynamique entre ces deux variables climatiques et d'identifier d'éventuelles évolutions interannuelles.

Query results | Query stats

Completed — Time in queue: 122 ms — Run time: 1.33 sec — Data scanned: 95.18 MB

Results (8) — Copy — Download results CSV

Search rows

#	annee	corr_pression_temperature
1	2019	0.077
2	2020	-0.149
3	2021	-0.012
4	2022	-0.347
5	2023	-0.286
6	2024	-0.315
7	2025	-0.192
8	2026	-0.411

figure 11 Influence de la pression sur la température (corrélation annuelle)

5) Analyse multivariée

Afin d'analyser les facteurs météorologiques susceptibles d'influencer l'amplitude thermique journalière, une étude de corrélation a été réalisée à l'échelle trimestrielle entre l'amplitude thermique, l'humidité moyenne et la pression atmosphérique moyenne.

Pour chaque journée, l'amplitude thermique a été calculée comme la différence entre la température maximale et minimale, tandis que l'humidité et la pression ont été agrégées sous forme de moyennes journalières. Les coefficients de corrélation ont ensuite été calculés par année et par trimestre afin d'identifier d'éventuelles variations saisonnières.

Les résultats montrent une corrélation majoritairement négative entre l'humidité moyenne et l'amplitude thermique, souvent comprise entre −0.3 et −0.7, ce qui suggère que des niveaux d'humidité plus élevés sont généralement associés à une réduction de la variation thermique quotidienne. En revanche, la corrélation entre la pression atmosphérique moyenne et l'amplitude thermique apparaît plus faible et

instable selon les périodes, indiquant que la pression constitue un facteur explicatif secondaire dans la dynamique de l'amplitude thermique.

Completed — Time in queue: 86 ms — Run time: 1.638 sec — Data scanned: 106.24 MB

Results (28) — Copy — Download results CSV

Search rows

#	annee	trimestre	correlation_humidite_amplitude	correlation_pression_amplitude
1	2019	2	-0.647	-0.081
2	2019	3	-0.519	0.061
3	2019	4	-0.461	0.059
4	2020	1	-0.138	0.218
5	2020	2	-0.538	0.226
6	2020	3	-0.662	-0.034
7	2020	4	-0.185	0.371
8	2021	1	-0.418	0.501
9	2021	2	-0.535	0.218
10	2021	3	-0.549	-0.113

figure 12 Analyse multivariée des corrélations saisonnières

6 Visualisation

Après la phase de transformation et de stockage dans la couche curated/, les données sont rendues exploitables via Amazon Athena afin de permettre l'exécution de requêtes SQL analytiques.

1) Architecture d'accès aux données

Dans le cadre du projet, une instance Amazon EC2 a été utilisée comme environnement d'exécution pour :

- interagir avec Amazon Athena via des requêtes SQL,
- développer une interface de visualisation à l'aide de Streamlit,
- centraliser la logique applicative côté serveur.

L'instance EC2 a été créée sous le rôle IAM LabInstanceProfile, garantissant les permissions nécessaires pour accéder à Athena et aux ressources S3 du projet. L'accès à l'instance s'effectue via terminal sécurisé (SSH) en utilisant les identifiants temporaires fournis par l'environnement Sandbox.

2) Interaction EC2 – Athena

Un script Python exécuté sur EC2 permet :

1. d'envoyer des requêtes SQL à Amazon Athena ;

2. d'attendre l'exécution de la requête ;
3. de récupérer les résultats ;
4. de charger les données dans un format exploitable (DataFrame)

Athena interroge directement les données présentes dans le dossier curated/ du data lake S3, garantissant que seules les données validées sont utilisées pour l'analyse.

Cette architecture évite tout stockage intermédiaire supplémentaire et s'appuie sur une approche serverless analytics.

3) Visualisation avec Streamlit

L'outil Streamlit a été déployé sur l'instance EC2 afin de fournir une interface web interactive permettant :

- la sélection de périodes temporelles,
- le choix du niveau d'agrégation (horaire, journalier, etc.),
- l'exécution dynamique de requêtes SQL,
- l'affichage de graphiques et indicateurs statistiques.

Streamlit agit comme couche de présentation, tandis qu'Athena assure la couche analytique et S3 la couche de stockage.

4) Résultats

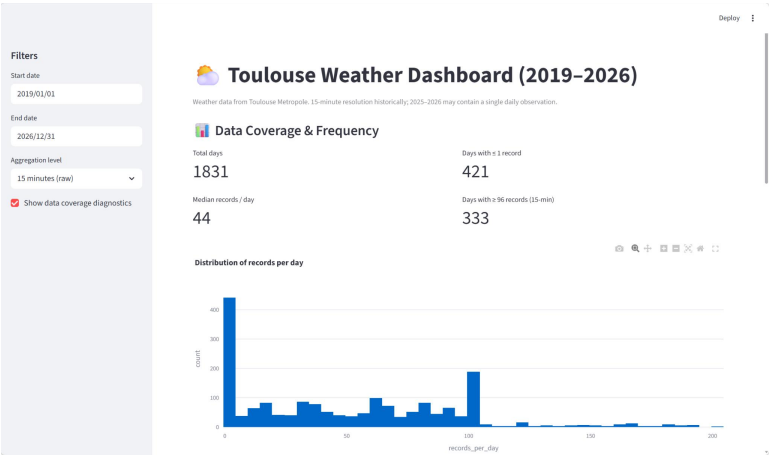

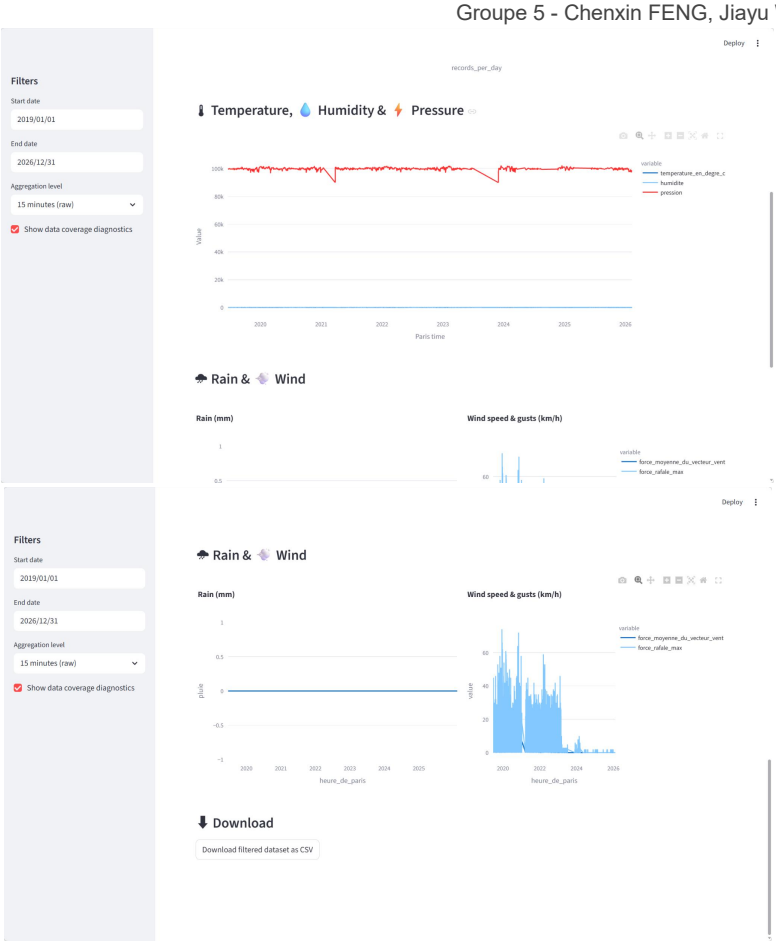

figure 13 Interface de visualisation des données météorologiques

7 Conclusion

Ce projet a permis de concevoir et déployer une architecture cloud complète dédiée au traitement et à l'analyse de données météorologiques issues de la plateforme open data de Toulouse Métropole.

L'architecture mise en place repose sur un pipeline ETL serverless combinant Amazon EventBridge, AWS Lambda, Amazon S3, AWS Glue, AWS CloudFormation et Amazon Athena. Cette approche facilite la mise en place globale du système, garantit une ingestion automatisée, une validation rigoureuse des données ainsi qu'une séparation claire entre données brutes, données validées et données en quarantaine.

L'intégration d'une interface de visualisation développée avec Streamlit sur une instance EC2 permet d'illustrer la chaîne complète de valorisation des données, depuis l'API source jusqu'à l'analyse interactive via SQL.

Des améliorations futures pourraient inclure l'optimisation du format de stockage (par exemple Parquet), l'intégration de mécanismes avancés de monitoring et l'automatisation complète du déploiement via une approche CI/CD.